

Traduction d'OCaml vers une variante de Système F

Jonathan Protzenko
sous la direction de François Pottier

June 15, 2010

Plan

Introduction

Aperçu du problème
Contributions

Décoration d'ASTs

Traduction(s)

Système F plus coercions

Conclusion

Plan

Introduction

Aperçu du problème

Contributions

Décoration d'ASTs


Traduction(s)

Système F plus coercions

Conclusion

Pourquoi traduire?

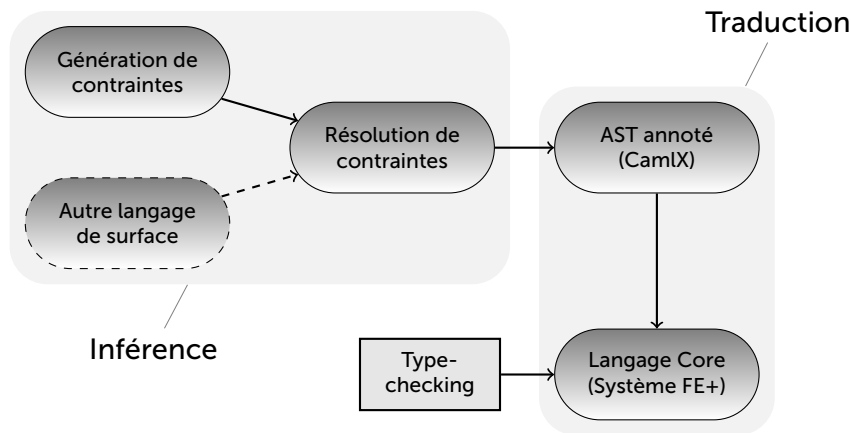
- On veut augmenter la confiance dans la chaîne de compilation
- "Well-typed programs can't go wrong" (Milner)
- Le système de types d'OCaml est trop complexe
 - Traduire le programme dans un langage de base
 - Vérifier le typage *a posteriori*



Objectifs à long terme

- Fournir un langage intermédiaire pour *effectuer des analyses* et compiler plus en avant: expressions *simples*, informations de type *riches*.
- Augmenter la confiance dans la chaîne de compilation: à défaut de prouver la correction du typeur, prouver la cohérence de ses résultats.
- Clarifier la sémantique du langage original: quelles sont les constructions qui s'expriment bien dans FE+?

Dans les grandes lignes...



Le processus se découpe en deux parties : génération/résolution de contraintes, et traductions jusqu'à Système FE+.

Plan

Introduction

Aperçu du problème

Contributions

Décoration d'ASTs

Traduction(s)

Système F plus coercions

Conclusion

Trois grands axes de travail

- Récrire un système d'inférence par contraintes, et l'adapter pour donner un *AST annoté*.
- Élaborer un processus de traduction d'un fragment d'OCaml vers un langage minimaliste
- Concevoir le système de types qui permet de justifier le comportement d'OCaml

```

protzenk@sauternes:~ ...  X  protzenk@sauternes:~ ...  X  prot
fun (x: 0) -> fun (y: 1) -> x
in
let i: AM. [1 -> 1] =
  s [1, 1, 0 -> 1] k [1, 0 -> 1] k [1, 0]
in
()
[DLet] Found a regular let
[DLet] Found a regular let
[DLet] Found a regular let
let s/70 =
  AM. λ (x/75: 1 -> 0 + 2) ->
    λ (y/76: 1 -> 0) ->
      λ (z/77: 1) ->
        (x/75) z/77 (y/76) z/77
in
let k/71 =
  AM. λ (x/73: 0) ->
    λ (y/74: 1) ->
      x/73
in
let i/72 =
  AM. (s/70 • [1] • [1] • [0 -> 1]) k/71 • [1] • [0 -> 1] k/71 • [1] • [0]
in
()
  
```


Plan

Introduction

Décoration d'ASTs

Le cœur du problème

Garder les annotations à portée de main

Traduction(s)

Système F plus coercions

Conclusion

Plan

Introduction

Décoration d'ASTs

Le cœur du problème

Garder les annotations à portée de main

Traduction(s)

Système F plus coercions

Conclusion

L'inférence par contraintes

- Nouvelle présentation d'un algorithme « classique »
- Séparation claire et élégante entre génération et résolution
- Préférable à l'implémentation OCaml, performante mais difficile d'accès

Exemple:

$$\llbracket \lambda z. t : T \rrbracket = \exists X_1 X_2. (\text{let } z : X_1 \text{ in } \llbracket t : X_2 \rrbracket \wedge X_1 \rightarrow X_2 \leq T)$$

Que fait l'inférence par contraintes?

L'inférence par contraintes répond oui ou non.

Au mieux, affiche les types inférés des définitions top-level.

```
let (x, y) = (fun x -> x) (1, fun x -> x)
```

```
val x: int
```

```
val y:  $\forall \alpha. \alpha \rightarrow \alpha$ 
```

Comment l'adapter pour afficher un AST annoté?

(Pas de valeur restriction dans les exemples)

Plan

Introduction

Décoration d'ASTs

Le cœur du problème

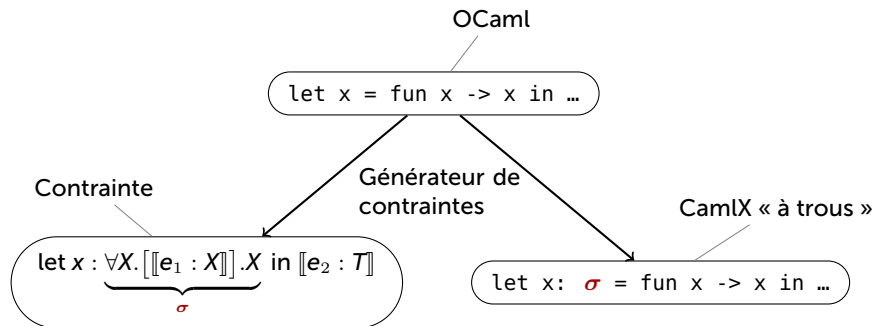
Garder les annotations à portée de main

Traduction(s)

Système F plus coercions

Conclusion

Une méthode ad-hoc



Idée: le générateur de contraintes renvoie *deux* arbres qui *partagent* des structures σ décrivant les schémas de type.

Fonctionnement de cette méthode

- Le générateur de contraintes *pré-alloue* des « boîtes vides » correspondant aux futurs résultats du solveur de contraintes.
- Le solveur résout la contrainte, et remplit au passage les boîtes.
- Les boîtes sont partagées: après la résolution des contraintes, les trous sont remplis, et l'AST « CamlX » est désormais annoté.

Avec un peu de recul...

- Simple et efficace : il s'agit de « faire suivre » les informations nécessaires.
- Facile à implémenter : solution d'une remarquable flexibilité.
- Peu élégant : le contenu des boîtes expose les structures internes du solveur.
- Pas de scope: les schémas de type sont extrudés, sortis de leur contexte.
- Formalisation difficile.

Il faudrait arriver à une forme plus propre et plus propice aux transformations...

Plan

Introduction

Décoration d'ASTs

Traduction(s)

Le décodeur

Le désucreur

Système F plus coercions

Conclusion

Plan

Introduction

Décoration d'ASTs

Traduction(s)

Le décodeur

Le désucreur

Système F plus coercions

Conclusion

De CamlX « à trous »...

... vers CamlX « tout court »

- Se passer des champs mutables et des classes d'équivalence
- Types en indices de De Bruijn
- Ne pas changer les expressions, simplement les types

```
let (x, y): ∀. [int * (0 → 0)] = Λ.
  (fun (x: int * (0 → 0)) -> x)
  (1, (fun (x: 0) -> x))
in
()
```

Remplissage des boîtes...

Sont conservées les schémas de types et les variables d'instanciation.

Les schémas sont résolus au niveau des contraintes `let`.

`function`, `fun`, `let`, `match` → contrainte `let`. Donc :

- créer une boîte ;
- l'attacher à la contrainte `let` ;
- l'attacher au nœud `CamlX` correspondant.

... et nettoyage

Les structures union-find sont mutables et contiennent du partage. On utilise des types avec des indices de De Bruijn.

- La généralisation se fait au niveau des `let` : pas de nœud Λ dans la syntaxe des expressions ;
- L'application de type se fait au niveau des instanciations : pas de nœud « application de type » ;
- les patterns sont présents dans les `let` et `function` ;
- les `let` sont multiples.

CamlX:

Une représentation avec des types clairs mais des expressions complexes.

Plan

Introduction

Décoration d'ASTs

Traduction(s)

Le décodeur

Le désucreur

Système F plus coercions

Conclusion

Désucrer CamlX vers...

... Système FE+

match

```
  Λ. (λ (x/41: int * (0 → 0)) -> x/41)
      (1, (λ (x/42: 0) -> x/42))
```

with

```
  | (x/39, y/40) ▶ ∀x; x0[•[bottom]] ->
    ()
```

Liste des modifications

- Les patterns sont utilisés à de nombreux endroits en OCaml: on les restreint aux `match` uniquement.
- Les `let` and peuvent définir simultanément plusieurs motifs: on utilise des identifiants uniques pour s'en passer.
- Les Λ et les applications de types deviennent des nœuds normaux de la syntaxe des expressions.

... et surtout, sont ajoutées des coercions.

Plan

Introduction

Décoration d'ASTs

Traduction(s)

Système F plus coercions

Présentation des coercions

Règles de génération de coercions

Conclusion

Plan

Introduction

Décoration d'ASTs

Traduction(s)

Système F plus coercions

Présentation des coercions

Règles de génération de coercions

Conclusion

Aperçu du problème

Reprenons l'exemple initial.

```
let (x, y) = (fun x -> x) (1, fun x -> x)
```

| À gauche | À droite |
|--------------------------------------|--|
| (x, y) | $\forall \alpha. (\text{int}, \alpha \rightarrow \alpha)$ |
| $\text{PCons}(\text{Tuple}, [x; y])$ | $\text{Forall} (\text{TCons} (\text{Tuple}, [\text{int}; \dots]))$ |

Head symbol mismatch: type $\forall \alpha. (\text{int}, \alpha \rightarrow \alpha)$ does not match pattern: Tuple...

(c'est une erreur de type)

Du sous-typage

Solution: Système F_η , ou « Système F avec sous-typage ».

- Par exemple, $\forall \alpha. (\tau_1, \tau_2) \leq (\forall \alpha. \tau_1, \forall \alpha. \tau_2)$.
- ... mais la relation de sous-typage est indécidable!
- Solution: attacher des coercions aux patterns.

$p \blacktriangleright c$: avant de filtrer sur p , appliquer la coercion c

Du sous-typage

Solution: Système F_η , ou « Système F avec sous-typage ».

- Par exemple, $\forall \alpha. (\tau_1, \tau_2) \leq (\forall \alpha. \tau_1, \forall \alpha. \tau_2)$.
- ... mais la relation de sous-typage est indécidable!
- Solution: attacher des coercions aux patterns.

$p \blacktriangleright c$: avant de filtrer sur p , appliquer la coercion c

Du sous-typage

Solution: Système F_η , ou « Système F avec sous-typage ».

- Par exemple, $\forall \alpha. (\tau_1, \tau_2) \leq (\forall \alpha. \tau_1, \forall \alpha. \tau_2)$.
- ... mais la relation de sous-typage est indécidable!
- Solution: attacher des coercions aux patterns.

$p \blacktriangleright c$: avant de filtrer sur p , appliquer la coercion c

Qu'est-ce qu'une coercion?

Une coercion est un témoin de sous-typage.

$$\frac{\Gamma \vdash c : \tau_i \leq \tau'_i}{\Gamma \vdash (\times_i[c]) : (\tau_1, \dots, \tau_i, \dots, \tau_n) \leq (\tau_1, \dots, \tau'_i, \dots, \tau_n)} \quad (\text{projection-tuple})$$

$$\frac{\Gamma \vdash c : \tau \leq \tau'}{\Gamma \vdash (\forall[c]) : \forall \tau \leq \forall \tau'} \quad (\forall\text{-covariance})$$

$$\frac{\Gamma \vdash c_1 : \tau \leq \tau' \quad \Gamma \vdash c_2 : \tau' \leq \tau''}{\Gamma \vdash c_1; c_2 : \tau \leq \tau''} \quad (\text{transitivité})$$

$$\frac{}{\Gamma \vdash \bullet[\sigma] : \forall \tau \leq [\sigma/0]\tau} \quad (\forall\text{-élimination})$$

$$\frac{}{\Gamma \vdash (\forall \times) : \forall (\tau_1, \dots, \tau_n) \leq (\forall \tau_1, \dots, \forall \tau_n)} \quad (\forall\text{-distributivité})$$

Plan

Introduction

Décoration d'ASTs

Traduction(s)

Système F plus coercions

Présentation des coercions

Règles de génération de coercions

Conclusion

Comment générer les coercions ?

Un ensemble de règles statiques permet de générer les coercions adaptées à chaque situation, *par filtrage sur le type et le pattern*.

- Rentrer récursivement les \forall dans les tuples, grâce à $(\forall \times)$ et $(\forall[\bullet])$.
- Éliminer les quantifications \forall inutiles pour les identifiants grâce à $(\bullet[\perp])$ et $(\forall[\bullet])$.

Au moment du type-checking, on a une fonction
`apply_coercion: typ -> coercion -> typ.`

(exemple au tableau)

Vu de loin

La relation de sous-typage dans F_η est indécidable mais...

- on ne demande jamais: $\tau \leq \tau'$?,
- on génère des coercions *au préalable*,
- on sait toujours *comment* coercer et vers quel type,
- on opère sur un sous-ensemble des situations de sous-typage.

L'exemple initial

```
let (x, y) = (fun x -> x) (1, fun x -> x)
```

... devient

```
match
```

```
  Λ. (λ (x/41: int * (0 → 0)) -> x/41)
      (1, (λ (x/42: 0) -> x/42))
```

```
with
```

```
  | (x/39, y/40) ▶ ∀x; x0[•[bottom]] ->
    ()
```

Phase finale

On vérifie le langage « core »...

... répond toujours oui (**ouf** !).

Plan

Introduction

Décoration d'ASTs

Traduction(s)

Système F plus coercions

Conclusion

Conclusion

Plan

Introduction

Décoration d'ASTs

Traduction(s)

Système F plus coercions

Conclusion

Conclusion

Une expérience intéressante

- Poser les bases a été le plus difficile
- Dans le pipeline : value restriction, types algébriques
- Plus tard : variantes polymorphes (qu'ajouter dans le langage de base?), autres...

Peut-être beaucoup d'implémentation à venir.

Un *framework* pour l'inférence de types

- Adapter l'inférence par contraintes a été un gros travail
- ... en faire une bibliothèque d'inférence à la ML?
- Offrir une interface claire pour examiner les résultats du solveur.

Questions ?